



Classificação de faltas elétricas através de redes neurais

CPE 727 - Aprendizado Profundo

Lucas Alexandre (lucas.alexandre@coppe.ufrj.br)

17 de dezembro de 2025

Sumário

1 Introdução

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas



Objetivo do trabalho

1 Introdução

1. Classificação de curto-circuito em sistemas elétricos com elo em corrente contínua;
2. Comparação entre modelos de redes neurais (CNN, DNN, LSTM e CNN+LSTM);
3. Verificar Acurácia, Sensibilidade e Especificidade dos modelos;
4. Realizar uma revisão bibliográfica do assunto;

Sumário

2 Revisão Bibliográfica

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

Áreas Relacionadas

2 Revisão Bibliográfica

- Transitórios eletromagnéticos [1];
- Fluxo de potência probabilístico [2];
- Classificação de Faltas Elétricas [3];
- Localização de Faltas Elétricas [4];

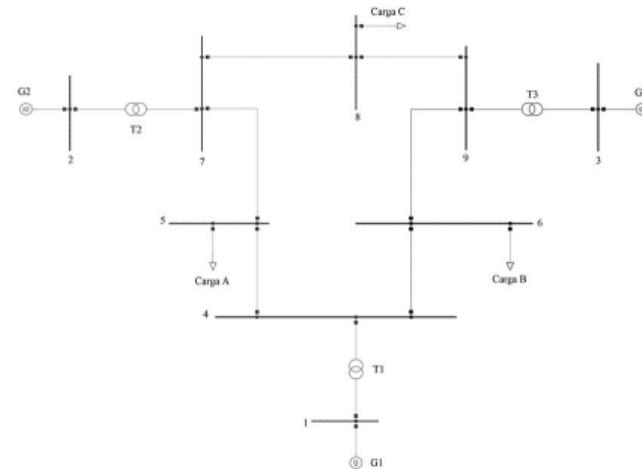


Figura: Sistema 9 barras

Modelos mais utilizados

2 Revisão Bibliográfica

- DNN (MLP - Multilayer Perceptron) [5] [6] [4];
- LSTM (Long Short-term Memory) [7] [8] [9];
- CNN (Convolutional Neural Network) [3] [10] [11];
- ARTMAP-Fuzzy [1] [12] [13];

Sumário

3 Metodologia

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas



Metodologia

3 Metodologia

1. Simulação do sistema elétrico no PSCAD, aplicando faltas em diversos pontos e com diversas impedâncias;
2. Geração do dataset com as medições elétricas em forma de séries temporais, salvando em csv e hdf;
3. Upload do dataset hdf no kaggle;
4. Dataloader;
5. Desenvolvimento dos modelos de redes neurais;
6. Treinamento dos modelos;
7. Obtenção dos resultados de classificação e das figuras de mérito;

Sumário

4 Sistema Elétrico simulado

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

CIGRÉ 563

4 Sistema Elétrico simulado

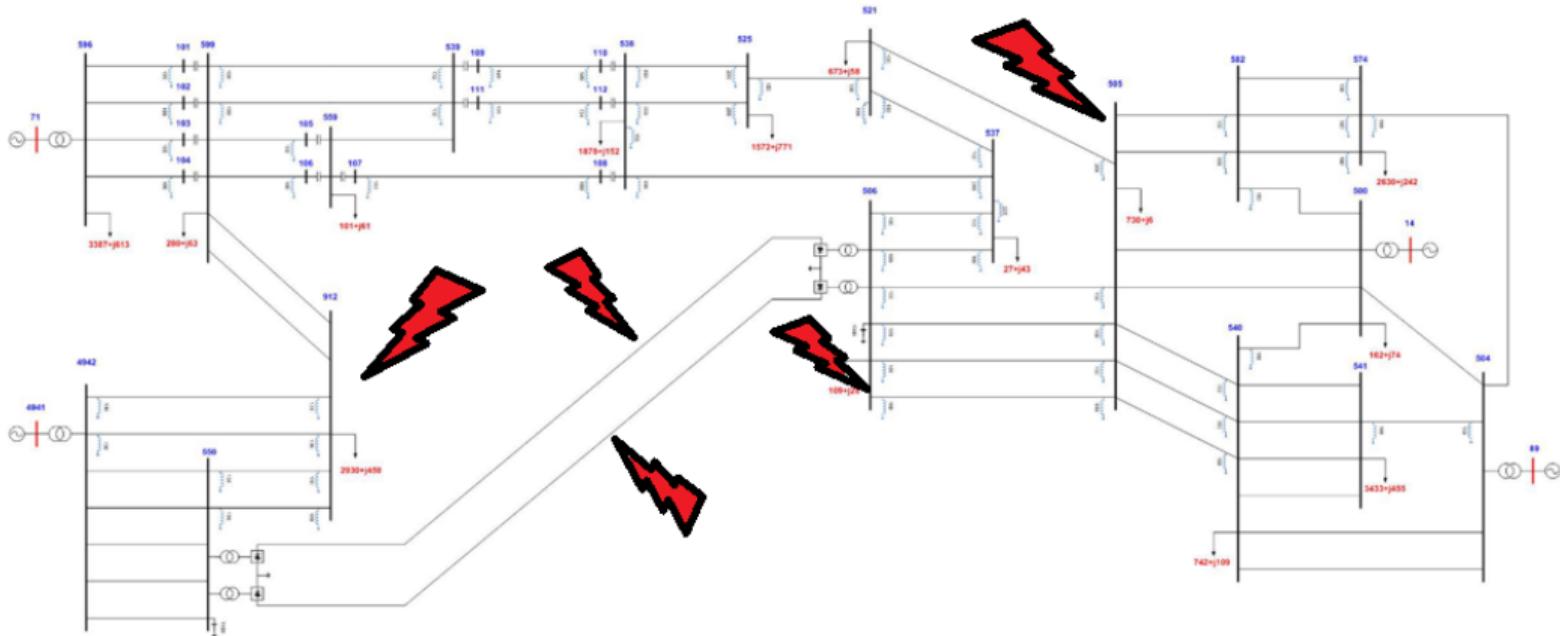


Figura: Modelo do sistema CIGRÉ 563 [14]



Simulação

4 Sistema Elétrico simulado

- 1170 casos;
- Duração de 8 s;
- Time step de $50 \mu\text{s}$;
- Curto AC aplicado nas barras 505, 506 e 912;
- Curto DC aplicado ao longo de 18 posições;
- Medições nas barras 550 e 506 e nas extremidades no elo CC;
- Curto aplicado em 6s e extinto após 0,1s;

Sumário

5 Tipos de Falta

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

Sistema sem faltas

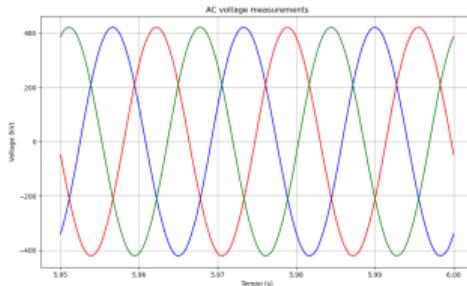


Figura: Tensão AC medida no inversor

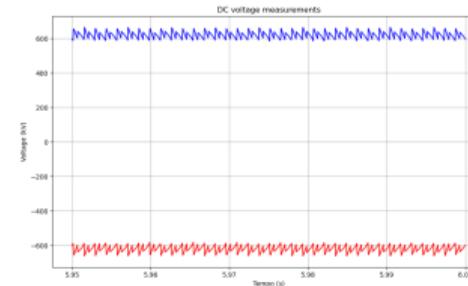
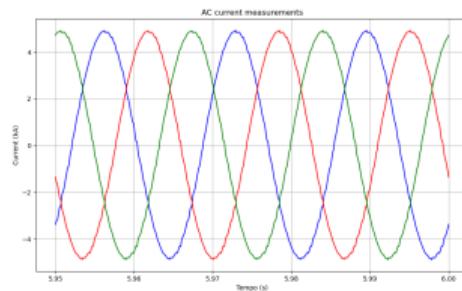


Figura: Tensão DC medida no retificador



13/49 Figura: Corrente AC medida no inversor

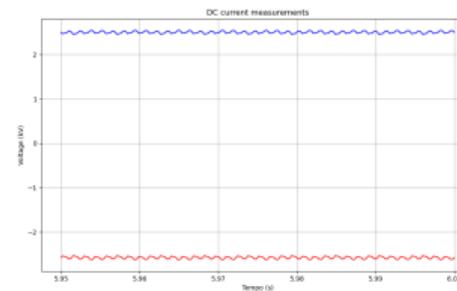


Figura: Tensão DC medida no retificador

Falta monofásica

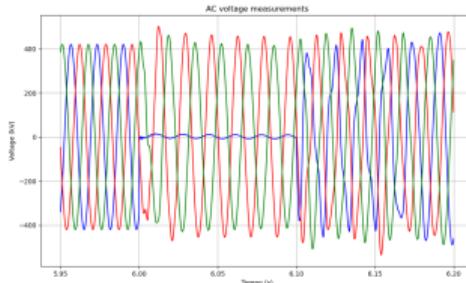


Figura: Tensão AC medida no inversor

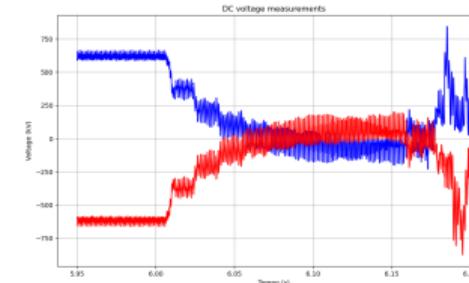
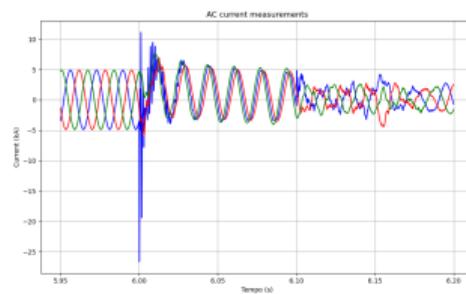


Figura: Tensão DC medida no retificador



14/49 Figura: Corrente AC medida no inversor

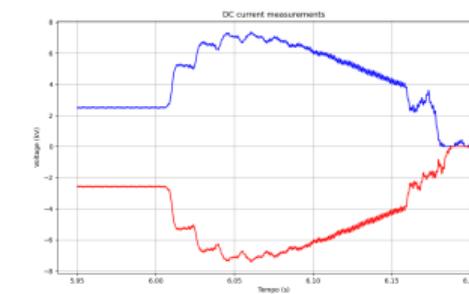


Figura: Corrente DC medida no retificador

Falta fase-fase

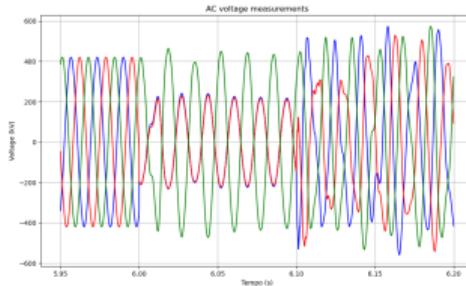


Figura: Tensão AC medida no inversor

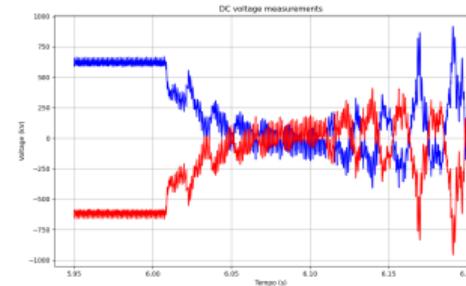
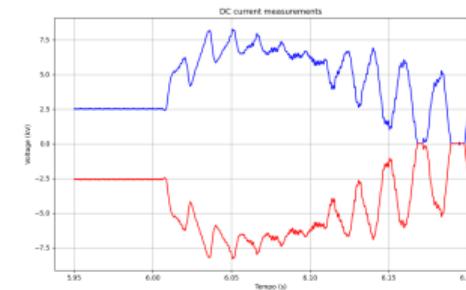
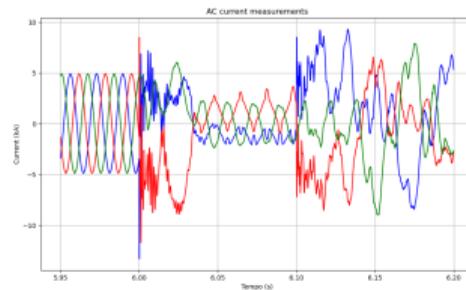


Figura: Tensão DC medida no retificador



15/49 Figura: Corrente AC medida no inversor

Figura: Corrente DC medida no retificador

Falta fase-fase-terra

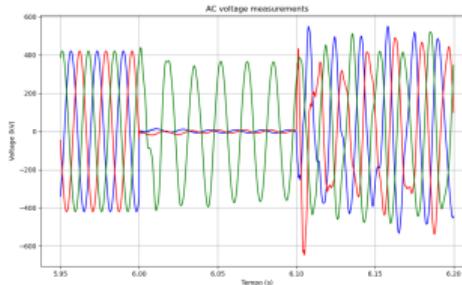


Figura: Tensão AC medida no inversor

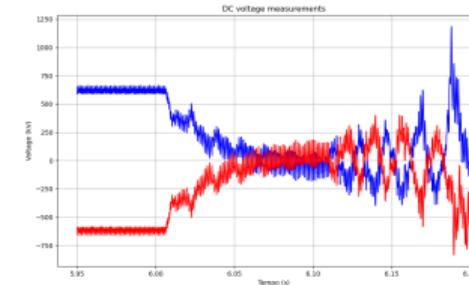
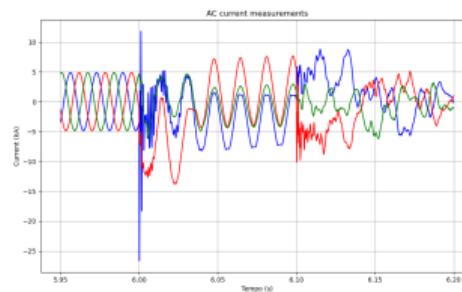


Figura: Tensão DC medida no retificador



16/49 Figura: Corrente AC medida no inversor

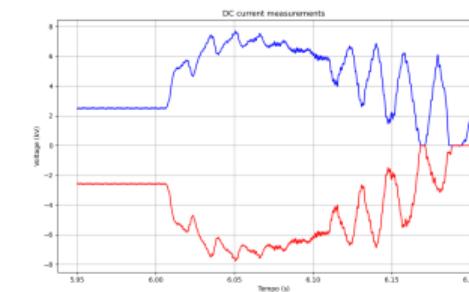


Figura: Corrente DC medida no retificador

Falta trifásica

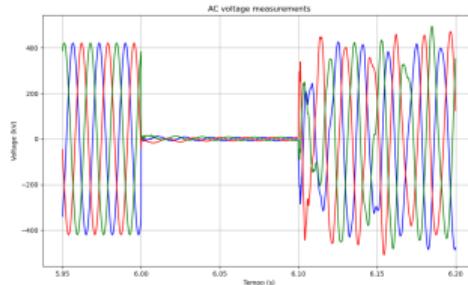


Figura: Tensão AC medida no inversor

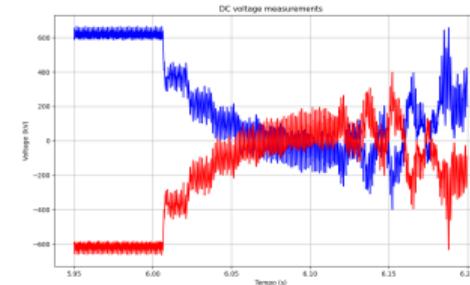
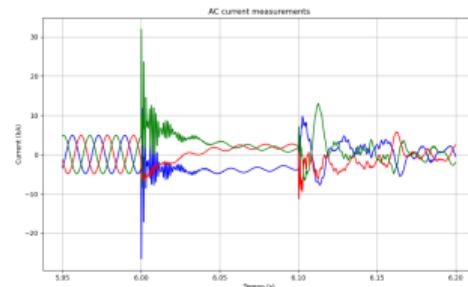


Figura: Tensão DC medida no retificador



17/49 Figura: Corrente AC medida no inversor

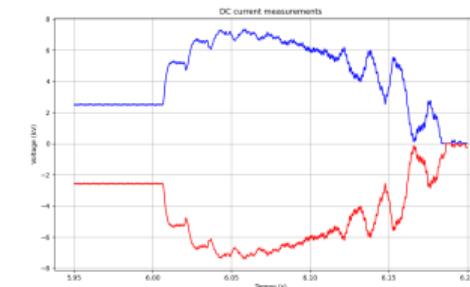


Figura: Corrente DC medida no retificador

Falta no polo positivo CC

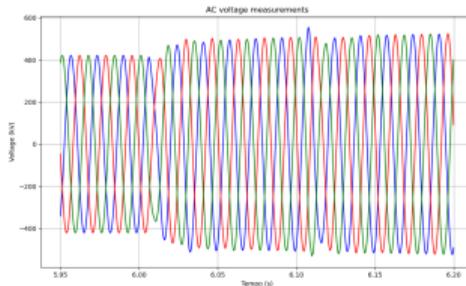


Figura: Tensão AC medida no inversor

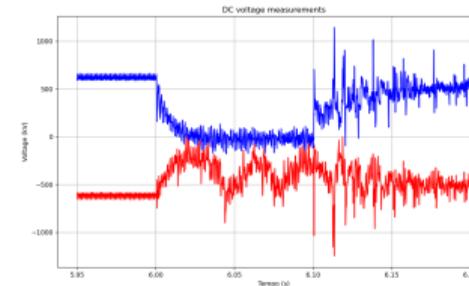
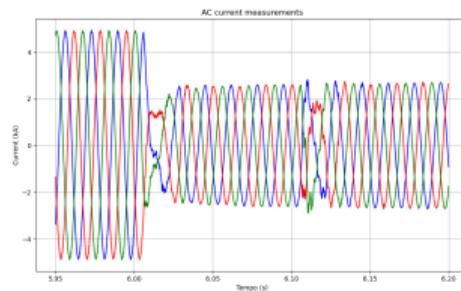


Figura: Tensão DC medida no retificador



18/49 Figura: Corrente AC medida no inversor

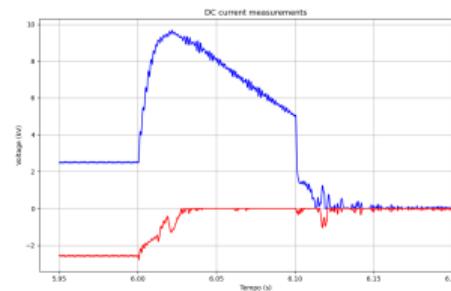


Figura: Corrente DC medida no retificador

Falta no polo negativo CC

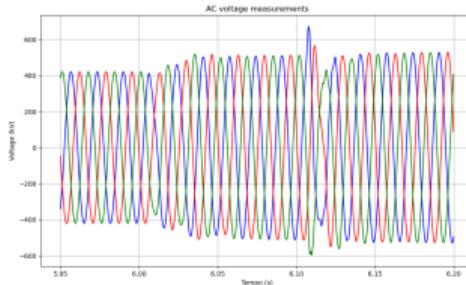


Figura: Tensão AC medida no inversor

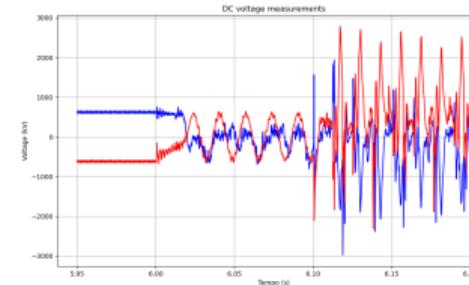
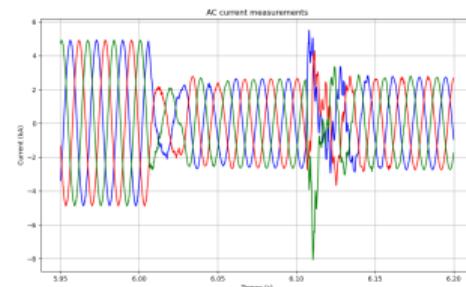


Figura: Tensão DC medida no retificador



19/49 Figura: Corrente AC medida no inversor

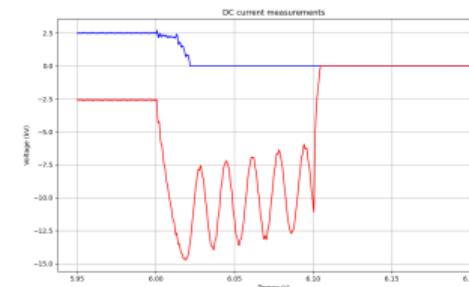


Figura: Corrente DC medida no retificador

Sumário

6 Resultados

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas



Dataset

6 Resultados

- Series temporais;
- 1170 amostras;
- 90 amostras por classe;
- Janela de 0,5 s antes e 0,5 s depois da falta;
- 70% treinamento, 15% validação e 15% teste;



Classes

6 Resultados

- **NF** — Cenário sem falta, utilizado como referência de operação normal.
- **A-G** — Curto entre a fase A e o terra.
- **B-G** — Curto entre a fase B e o terra.
- **C-G** — Curto entre a fase C e o terra.
- **A-B** — Curto entre as fases A e B.
- **B-C** — Curto entre as fases B e C.
- **C-A** — Curto entre as fases C e A.
- **AB-G** — Curto duplo entre as fases A-B e o terra.
- **BC-G** — Curto duplo entre as fases B-C e o terra.
- **CA-G** — Curto duplo entre as fases C-A e o terra.
- **ABC-G** — Curto trifásico com envolvimento do terra.
- **DC+** — Curto no polo positivo do elo CC.
- **DC-** — Curto no polo negativo do elo CC.



Figuras de mérito

6 Resultados

$$\text{Acurácia} = \frac{TP + TN}{TP + FP + TN + FN} \quad [15] \quad (1)$$

$$\text{Sensibilidade} = \frac{TP}{TP + FN} \quad [15] \quad (2)$$

$$\text{Especificidade} = \frac{TN}{TN + FP} \quad [15] \quad (3)$$



CNN - Arquitetura

6 Resultados

- 20 canais;
- 3 camadas (32, 64, 128) → 1 escondida;
- kernel: 3;
- Ativação: ReLU;
- Batch Normalization (32, 64, 128);
- Max Pool(2) em cada camada;
- 60 épocas;
- Critério: CrossEntropyLoss;
- Otimizador: Adam;
- learning rate: 1e-4;

CNN

6 Resultados

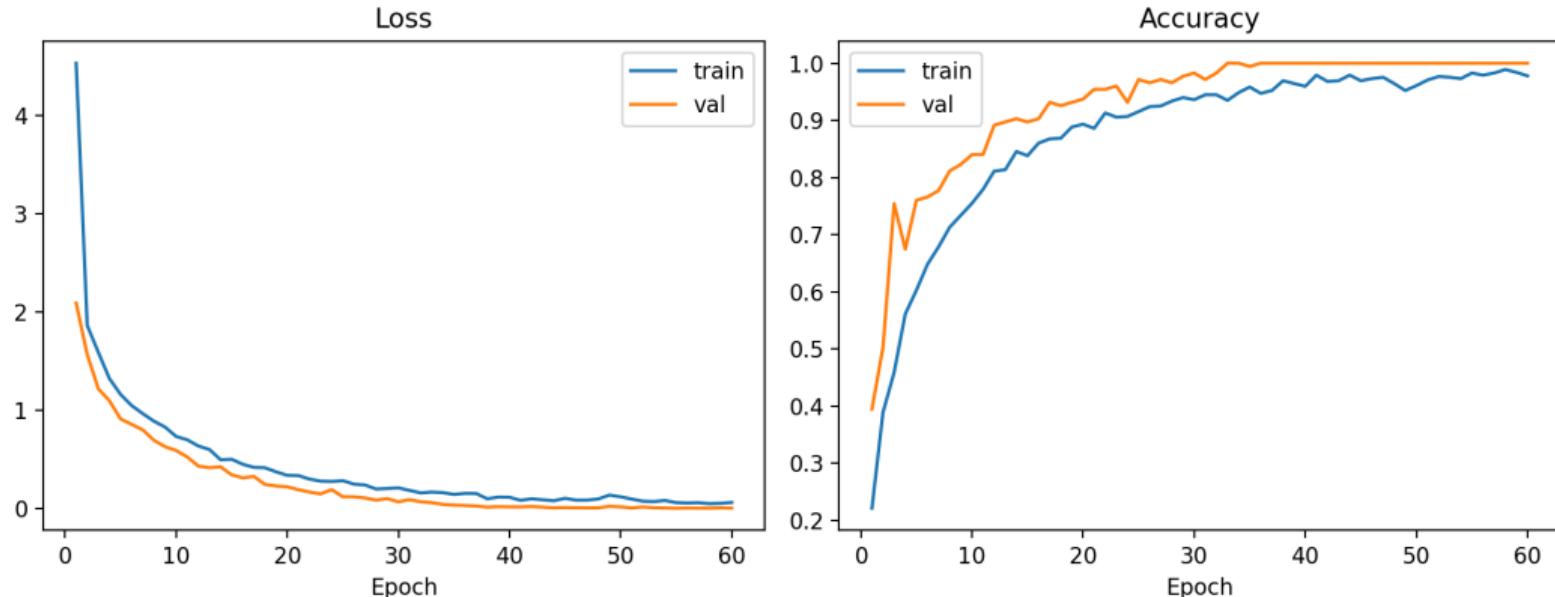


Figura: Curvas de treinamento do CNN

CNN

6 Resultados

- Acurácia = 99,42 %
- Sensibilidade = 99,4 %
- Especificidade = 99,95 %

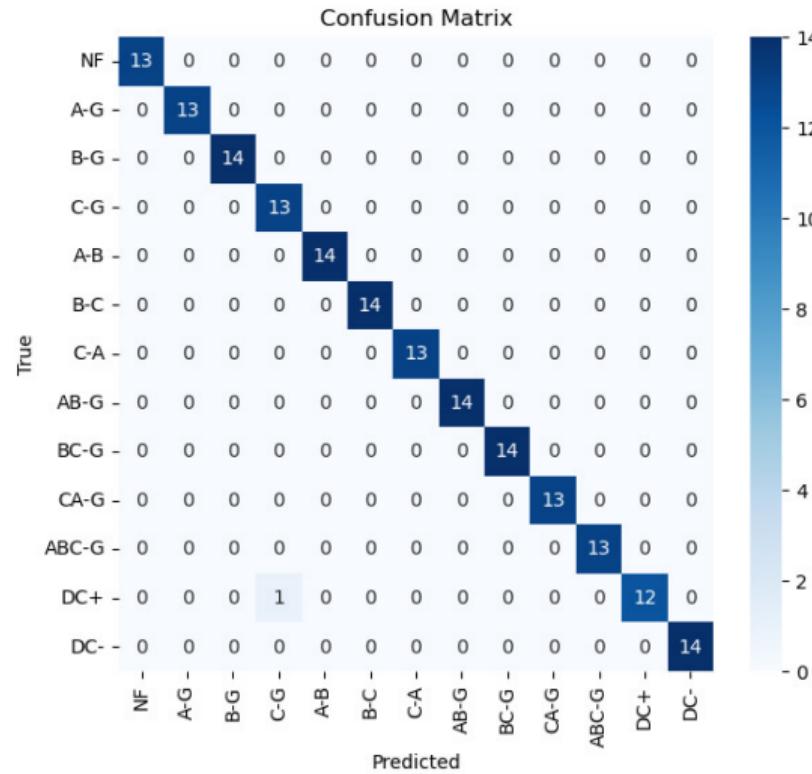


Figura: Matriz de confusão do CNN

CNN

6 Resultados

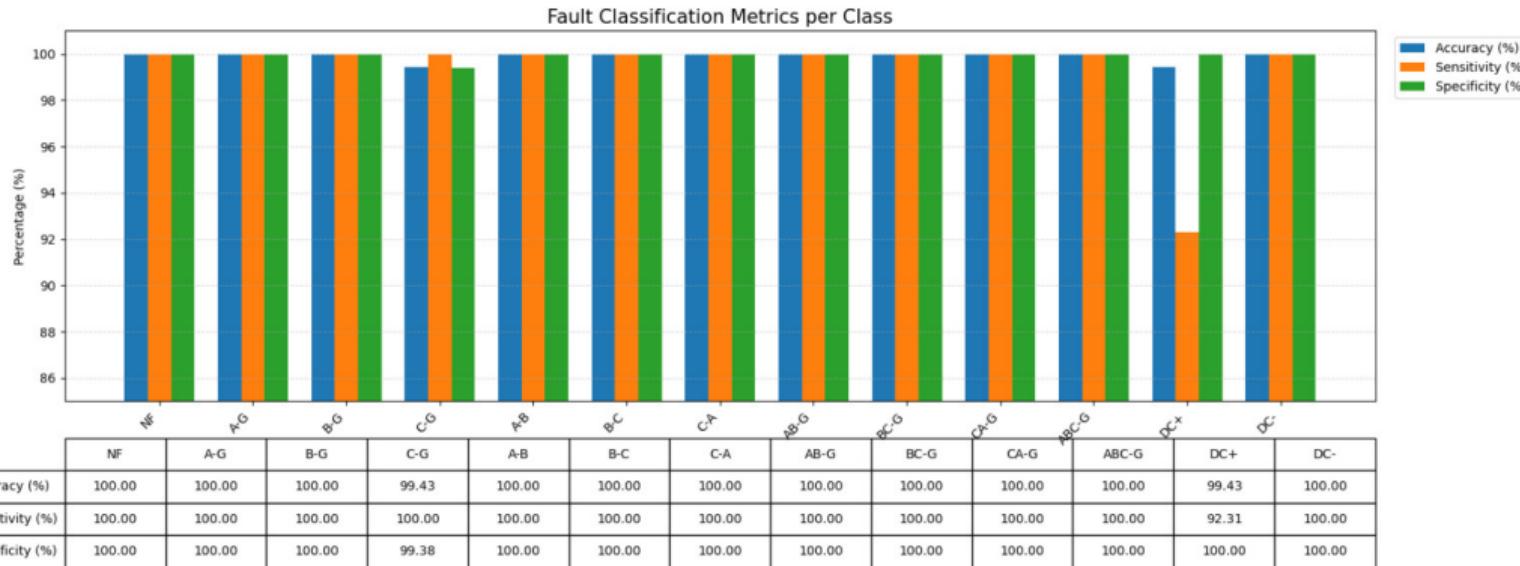


Figura: Figuras de mérito para cada classe no CNN



DNN - Arquitetura

6 Resultados

- 20 canais;
- 2 camadas (256, 128);
- Ativação: ReLU;
- Batch Normalization (256, 128);
- Dropout (0.05);
- 100 épocas;
- Critério: CrossEntropyLoss;
- Otimizador: AdamW;
- learning rate: 1e-5;

DNN

6 Resultados

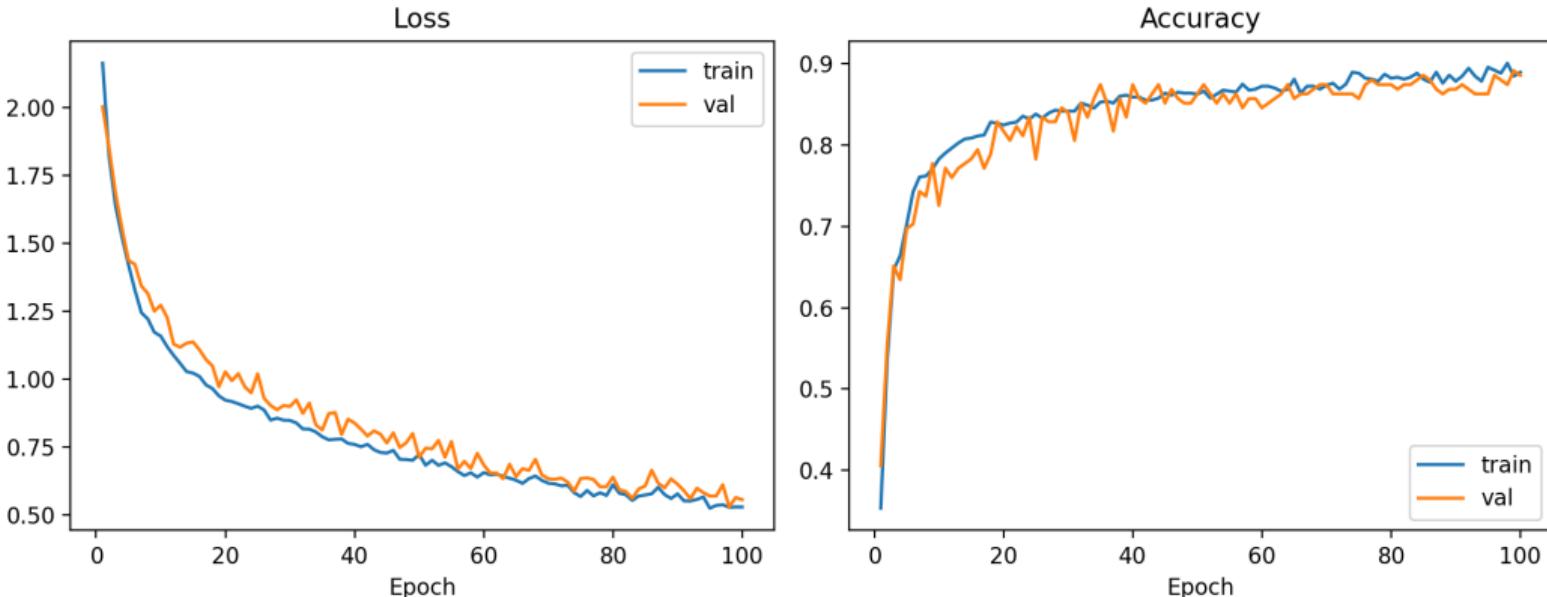


Figura: Curvas de treinamento

DNN

6 Resultados

- Acurácia = 85,14 %
- Sensibilidade = 85,2 %
- Especificidade = 98,76 %

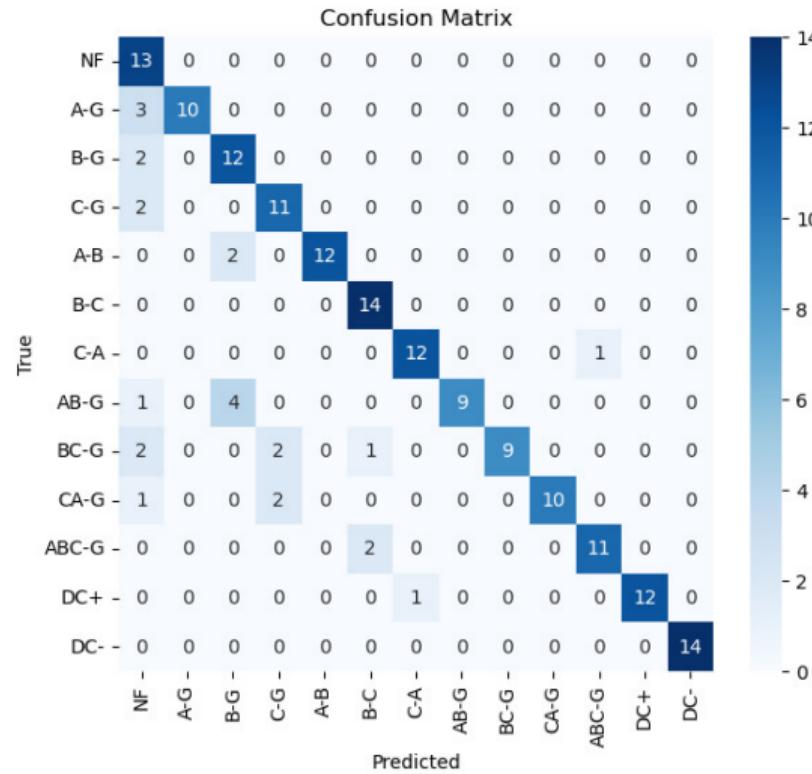


Figura: Matriz de confusão do DNN

6 Resultados

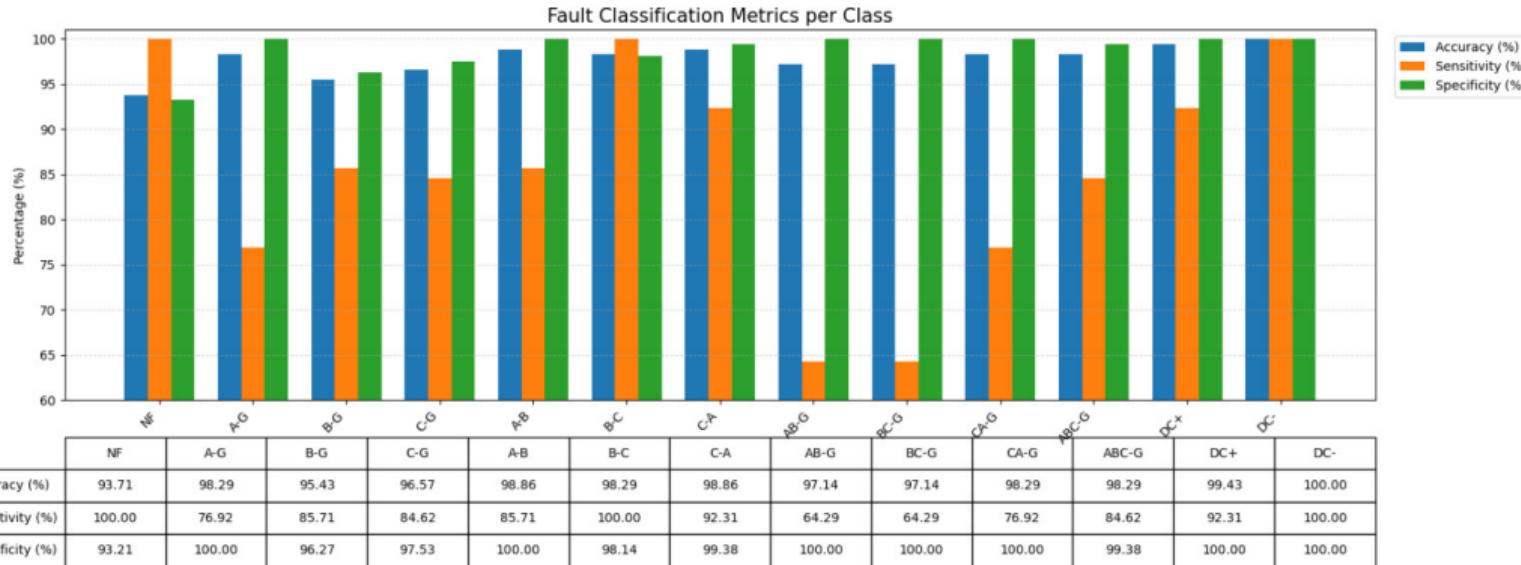


Figura: Figuras de mérito para cada classe no DNN



LSTM - Arquitetura

6 Resultados

- 20 canais;
- 2 camadas;
- Ativação: ReLU;
- Batch Normalization;
- Dropout (0.2);
- 100 épocas;
- Critério: CrossEntropyLoss;
- Otimizador: AdamW;
- learning rate: 1e-4;

LSTM

6 Resultados

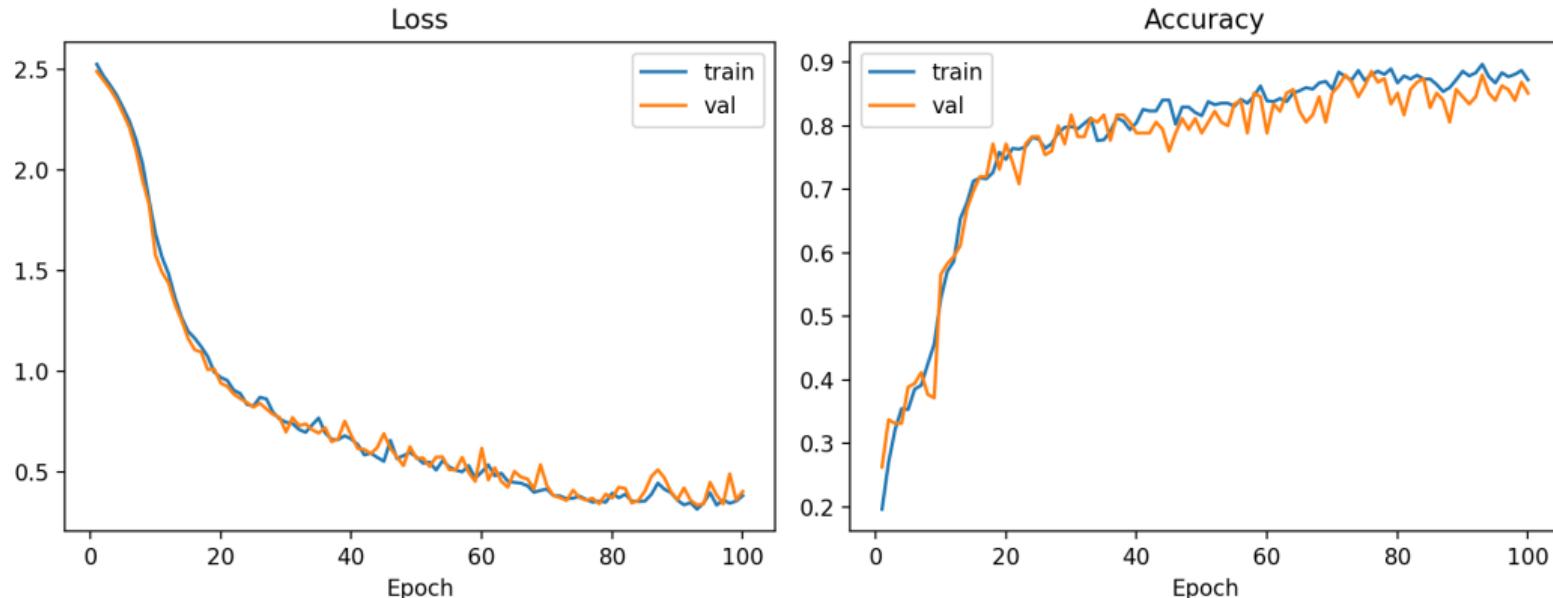


Figura: Curvas de treinamento do LSTM

LSTM

6 Resultados

- Acurácia = 86,28 %
- Sensibilidade = 86,43 %
- Especificidade = 98,85 %

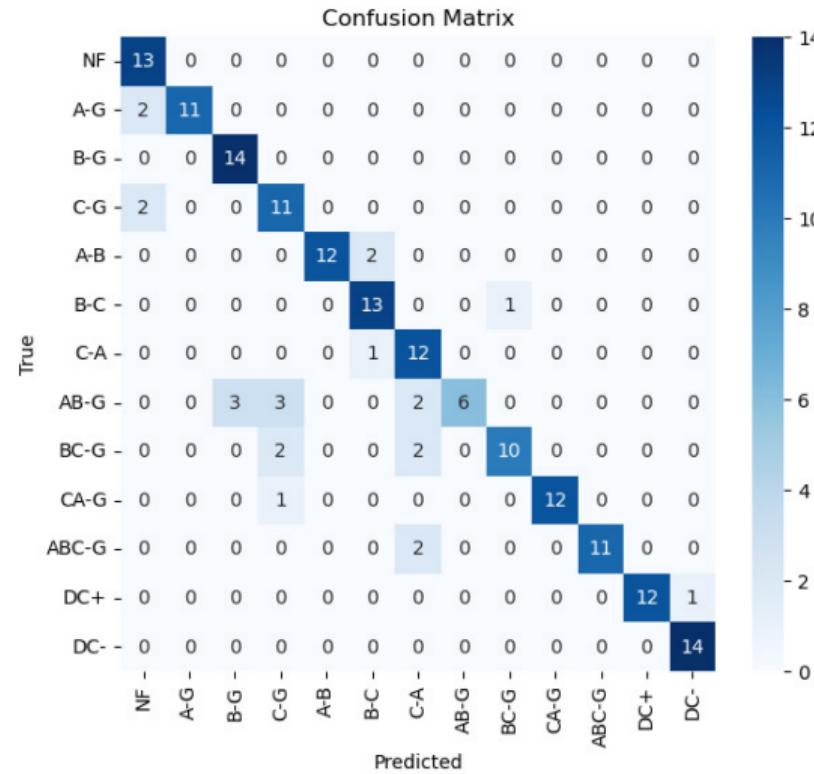


Figura: Matriz de confusão do LSTM

LSTM

6 Resultados

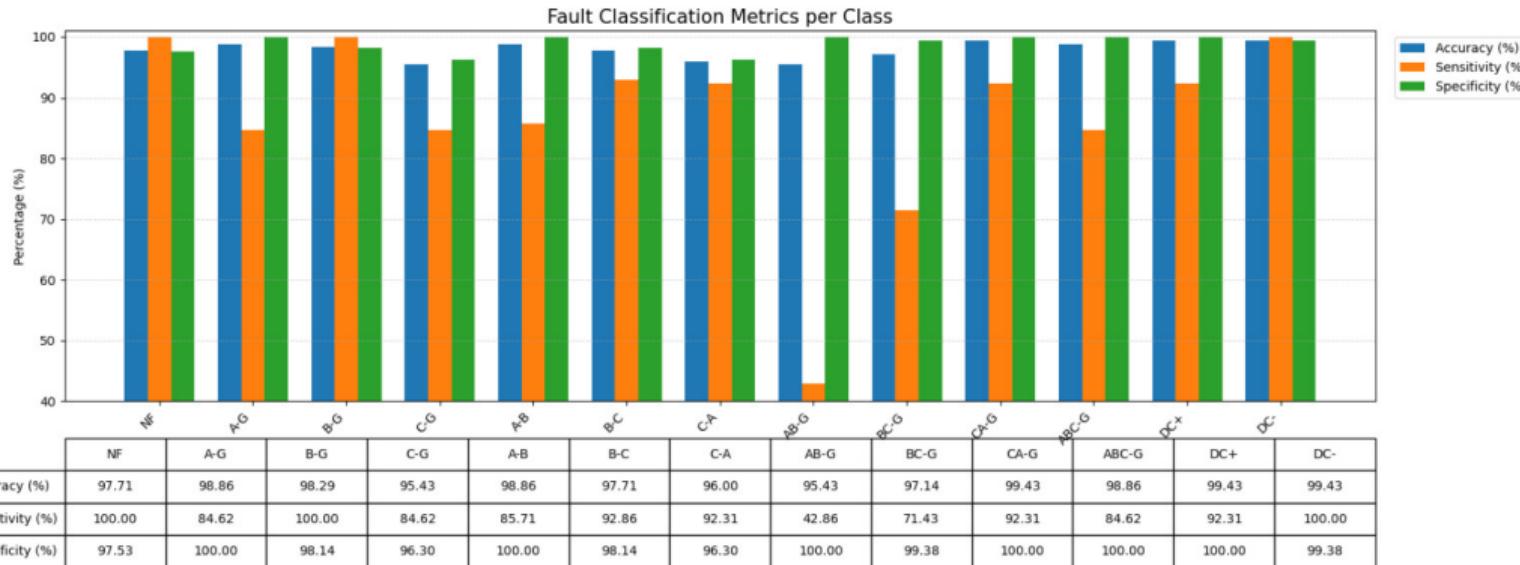


Figura: Figuras de mérito para cada classe no LSTM



CNN + LSTM - Arquitetura

6 Resultados

- 20 canais;
- 2 camadas convolucionais (16, 32) e uma de LSTM (128);
- Ativação: ReLU;
- Batch Normalization (16, 32) nas camadas de CNN;
- 100 épocas;
- Critério: CrossEntropyLoss;
- Otimizador: AdamW;
- learning rate: 1e-4;

CNN + LSTM

6 Resultados

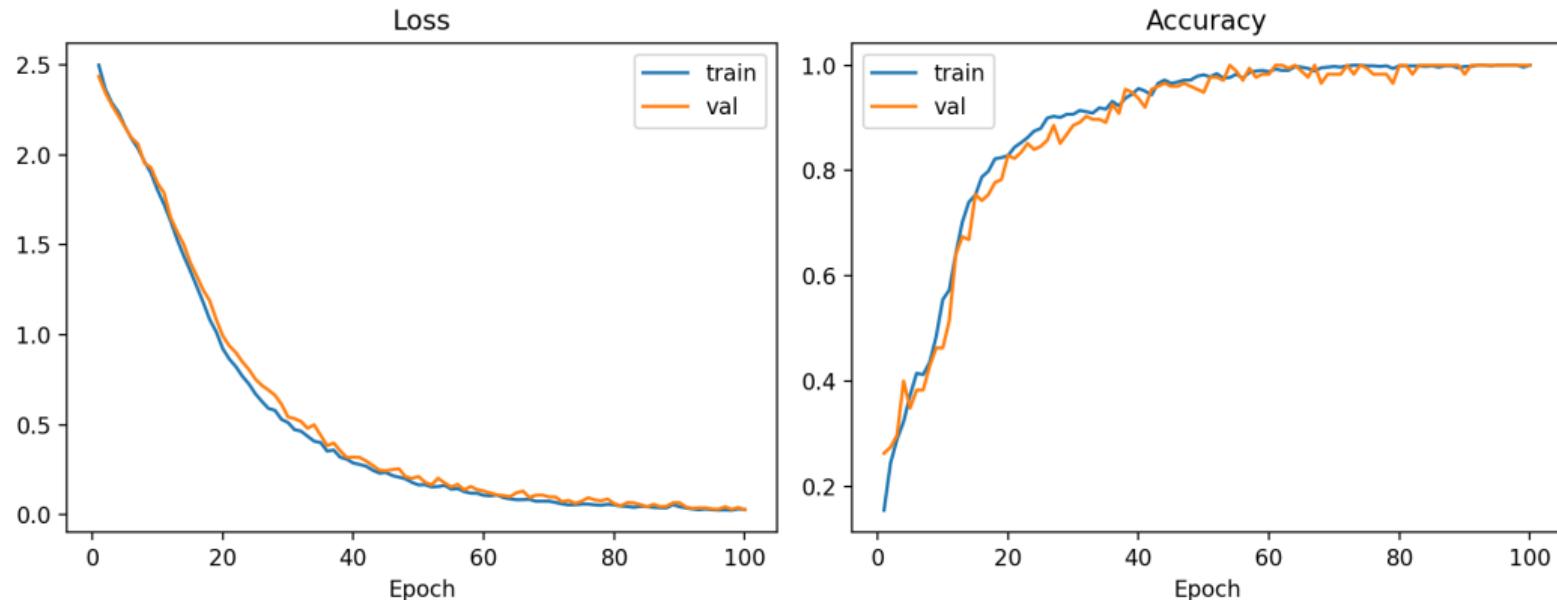


Figura: Curvas de treinamento do CNN+LSTM

CNN + LSTM

6 Resultados

- Acurácia = 98,28 %
- Sensibilidade = 98,3 %
- Especificidade = 99,85 %

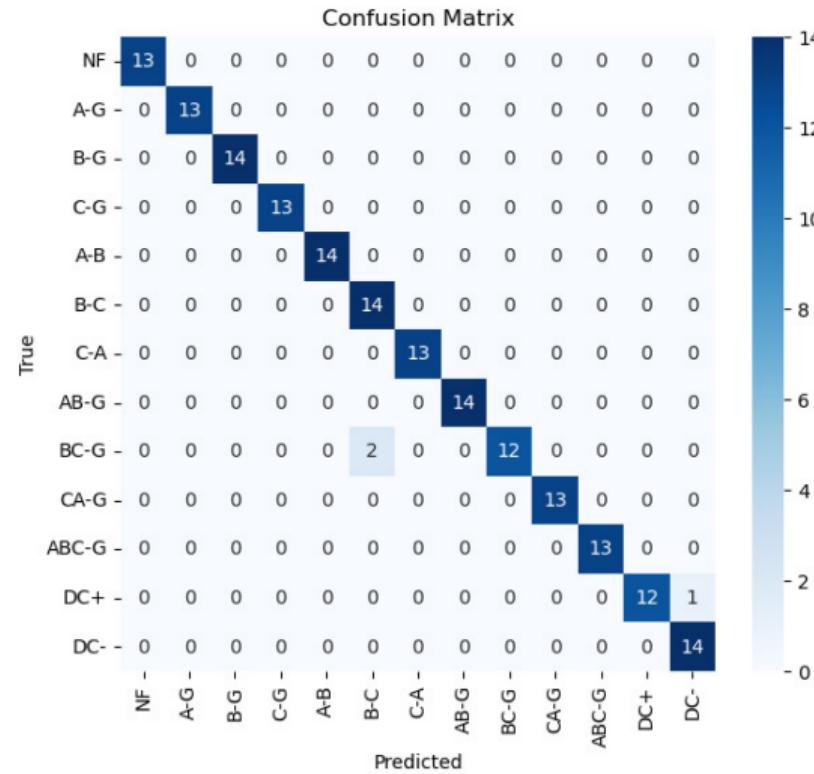


Figura: Matriz de confusão do CNN+LSTM

CNN + LSTM

6 Resultados

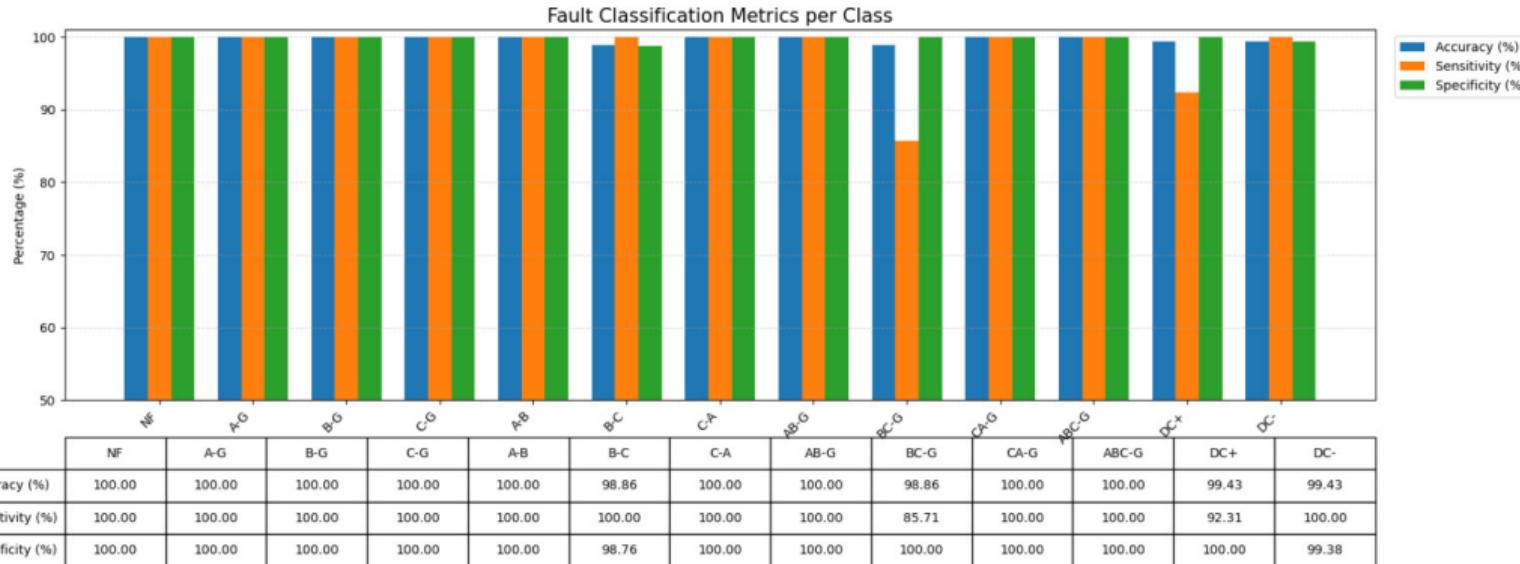


Figura: Figuras de mérito para cada classe no CNN+LSTM

Comparação entre modelos

6 Resultados

Modelo	Acurácia (%)	Sensibilidade (%)	Especificidade (%)
CNN	$99,428 \pm 0,278$	$99,408 \pm 0,48$	$99,95 \pm 1,44$
DNN	$85,142 \pm 6,004$	$85,207 \pm 4,44$	$98,762 \pm 4,512$
LSTM	$86,28 \pm 5,81$	$86,43 \pm 4,17$	$98,85 \pm 4,52$
CNN + LSTM	$98,2 \pm 0,49$	$98,3 \pm 1,11$	$99,85 \pm 2,75$

Tabela: Comparação entre os modelos desenvolvidos



Sumário

7 Conclusão

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

Conclusão

7 Conclusão

- Em todas as figuras de mérito, CNN é o melhor modelo para sistemas com elo CC;
- DNN não se mostrou um bom método para HVDC, mesmo sendo usado para redes AC;
- LSTM é um bom método quando combinado com outro método que faz uma extração de dados;

Sumário

8 Referências Bibliográficas

- ▶ Introdução
- ▶ Revisão Bibliográfica
- ▶ Metodologia
- ▶ Sistema Elétrico simulado
- ▶ Tipos de Falta
- ▶ Resultados
- ▶ Conclusão
- ▶ Referências Bibliográficas

Referências Bibliográficas

8 Referências Bibliográficas

- [1] S. C. Marchiori, C. R. Minussi, and A. D. P. Lotufo, "Rede neural artmap nebulosa para análise de estabilidade transitória de sistemas de energia elétrica," *Learning Nonlinear Models*, vol. 1, no. 1, pp. 49–65, 2003.
- [2] Y. Yang, Z. Yang, J. Yu, B. Zhang, Y. Zhang, and H. Yu, "Fast calculation of probabilistic power flow: A model-based deep learning approach," *IEEE Transactions on Smart Grid*, vol. 11, no. 3, pp. 2235–2244, 2020.
- [3] S. Jiriwibhakorn and S. Kanwal, "Time series-based fault detection and classification in ieee 9-bus transmission lines using deep learning," *IEEE Access*, vol. 13, pp. 118135–118146, 2025.



Referências Bibliográficas

8 Referências Bibliográficas

- [4] S. I. Ahmed, M. F. Rahman, S. Kundu, R. M. Chowdhury, A. O. Hussain, and M. Ferdoushi, “Deep neural network based fault classification and location detection in power transmission line,” in *2022 12th International Conference on Electrical and Computer Engineering (ICECE)*, pp. 252–255, 2022.
- [5] I. N. Silva, D. H. Spatti, and R. A. Flauzino, *Redes Neurais Artificiais: Para Engenharia e Ciências Aplicadas*. São Paulo: Artliber, 2 ed., 2010.
- [6] S. Senemmar and J. Zhang, “Deep learning-based fault detection, classification, and locating in shipboard power systems,” in *2021 IEEE Electric Ship Technologies Symposium (ESTS)*, pp. 1–6, 2021.



Referências Bibliográficas

8 Referências Bibliográficas

- [7] Q. Wang, Y. Yu, H. O. A. Ahmed, M. Darwish, and A. K. Nandi, "Open-circuit fault detection and classification of modular multilevel converters in high voltage direct current systems (mmc-hvdc) with long short-term memory (lstm) method," *Sensors*, vol. 21, no. 12, 2021.
- [8] A. M. Saidina Omar, M. Osman, M. Ibrahim, H. Zakaria, and A. Abidin, "Fault classification on transmission line using lstm network," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 20, p. 231, 10 2020.
- [9] A. S. Alhanaf, M. Farsadi, and H. H. Balik, "Fault detection and classification in ring power system with dg penetration using hybrid cnn-lstm," *IEEE Access*, vol. 12, pp. 59953–59975, 2024.



Referências Bibliográficas

8 Referências Bibliográficas

- [10] O. Turanlı and Y. Benteşen Yakut, "Classification of faults in power system transmission lines using deep learning methods with real, synthetic, and public datasets," *Applied Sciences*, vol. 14, no. 20, 2024.
- [11] S. M. Naidu, "Hvdc fault detection and identification in monopolar topology using deep learning," in *2022 12th International Conference on Power, Energy and Electrical Engineering (CPEEE)*, pp. 354–358, 2022.
- [12] S. C. Marchiori, *Desenvolvimento de um sistema para análise da estabilidade transitória de sistemas de energia elétrica via redes neurais*. Tese (doutorado), Universidade Estadual Paulista Julio de Mesquita Filho, Faculdade de Engenharia de Ilha Solteira, Ilha Solteira, 2006.



Referências Bibliográficas

8 Referências Bibliográficas

- [13] J. R. D. Martins, "Detecção e classificação de curtos-circuitos em sistemas de distribuição usando rede neural artificial artmap nebulosa," trabalho de conclusão de curso, UNESP, Ilha Solteira,SP, 2010.
- [14] CIGRE, *Modelling and Simulation Studies to be performed during the lifecycle of HVDC Systems.*
No. 563 in Technical Brochure, CIGRE, 2013.
Working Group B4.38.
- [15] R. S. Jawad and H. Abid, "Hvdc fault detection and classification with artificial neural network based on aco-dwt method," *Energies*, vol. 16, no. 3, 2023.

Classificação de faltas elétricas através de redes neurais

*Obrigado pela Atenção!
Alguma Pergunta?*

lucas.alexandre@coppe.ufrj.br