

Desenvolver um modelo gerador de séries temporais multivariadas para um compressor industrial offshore baseado em RNN e VAEs.

Rodrigo Petrus Domingues

CPE727 – Deep Learning

8 de dezembro de 2025

# Sumário

- 1 Motivação e Objetivos
- 2 Base de dados e pré-processamento
- 3 Formulação do Problema
- 4 Arquiteturas e Variações
- 5 Configuração Experimental
- 6 Resultados
- 7 Discussão e Conclusões

# Motivação e Objetivos do trabalho

## Motivação:

- Compressores industriais são ativos críticos (segurança, disponibilidade, custo).
- As séries temporais multivariadas de sensores refletem o estado operacional.
- Modelos generativos podem simular cenários operacionais variados.
- Gêmeos digitais e simulações realistas auxiliam na manutenção preditiva

## Objetivos do trabalho:

- Desenvolver **modelos geradores** de séries temporais multivariadas para um compressor industrial offshore.
- Aprender, de forma não supervisionada, a distribuição dos sinais de processo em janelas temporais.
- Gerar novas trajetórias plausíveis para:
  - simulação de cenários,
  - testes de algoritmos de monitoramento,
  - análise de variabilidade operacional.

## Comparar arquiteturas:

- Modelos DEEP, LSTM, GRU, BiLSTM e BiGRU com GRU fuser, todos com otimização Adam;
- Variações de treinamento (warmup, scheduler, RAdam, AdamW, variational dropout, difusão e layernorm).

## Base de dados

Cognite — sinais reais de sensores de um compressor industrial offshore.

Séries Temporais do Compressor



## Pré-processamento

- Estados operacionais:
  - Estados originais: 6 (0 a 5);
  - Estados finais: 3 (normal, alerta, falha).
- Normalização robusta (RobustScaler) por sensor;
- Série temporal com amostras a cada 5 minutos.
- Segmentação em janelas:
  - `window_size = 10, window_step = 10`
  - janelas não sobrepostas (modo gerador local).

# Definição do problema (modo gerador)

- Série multivariada:  $x_t \in \mathbb{R}^d$ ,  $t = 1, \dots, T$ , com  $d = 11$  sensores.
- Construímos janelas temporais:

$$X = (x_{t-L+1}, \dots, x_t) \in \mathbb{R}^{L \times d}$$

com  $L = 10$  passos de tempo.

- Objetivo: aprender um **modelo gerador** para as janelas  $X$ :

$$p_{\theta}(X) \approx p_{\text{dados}}(X)$$

- Modelo latente (VAE + difusão):
  - Encoder mapeia  $X$  para um código latente  $z$ ;
  - Decoder reconstrói  $\hat{X}$  a partir de  $z$ ;
  - O espaço latente é regularizado para permitir **amostrar novos**  $z$  e gerar janelas sintéticas.
- Uso principal:
  - Geração de séries realistas para simulação de cenários e testes de algoritmos de monitoramento.

O modelo aprende a **recrutar e amostrar** janelas de sensores compatíveis com o comportamento real do compressor.

# Função de custo (modo gerador)

- O modelo admite uma função de custo multi-termo:

$$\mathcal{L} = \lambda_m \mathcal{L}_{\text{miss}} + \lambda_v \mathcal{L}_{\text{vae}}$$

- O treinamento é **não supervisionado**, visando aprender:


$$p_{\theta}(X) \approx p_{\text{dados}}(X)$$

$$\mathcal{L}_{\text{miss}} = \text{BCE}(m, \hat{m}) \quad \text{com} \quad \hat{m} = \sigma(f_{\text{miss}}(h))$$

$$\mathcal{L}_{\text{vae}} = \underbrace{\mathbb{E}_{q(z|X)}[-\log p(X|z)]}_{\text{erro de reconstrução}} + \beta \underbrace{\text{KL}(q(z|X) \parallel \mathcal{N}(0, I))}_{\text{regularização do espaço latente}}$$


- BCE entre a máscara verdadeira de observação e a máscara prevista, forçando o estado latente a codificar o padrão temporal de missing.
- O termo de reconstrução garante fidelidade aos sinais reais.
- O termo KL força um espaço latente contínuo e amostrável.
- Isso permite **gerar novas janelas sintéticas** de sensores com propriedades estatísticas similares às observadas.

# Arquitetura base e arquiteturas avaliadas



- **Arquitetura base:** Encoder temporal recorrente acoplado a um VAE latente.
- A entrada  $X$  é codificada e passada ao **RNN encoder**, que parametriza  $(\mu_z, \log \sigma_z^2)$ .
- Amostramos  $z$  e o **decoder** reconstrói  $\hat{X}$  com média e variância  $(\mu_x, \log \sigma_x^2)$ .
- **Arquiteturas avaliadas:**
  - **TSDF\_DEEP:** baseline feedforward (sem recorrência);
  - **TSDF\_LSTM:** LSTM unidirecional e **BiLSTM**;
  - **TSDF\_GRU:** GRU unidirecional e **BiGRU**.


## BiLSTM + Warmup & Scheduler



- Aumenta gradualmente a taxa de aprendizado no início do treino;
- Evita instabilidades e melhora a convergência inicial.




## BiLSTM + RAdam




- Reduz a variância adaptativa do Adam nos primeiros passos;
- Torna o treinamento mais estável.

## BiLSTM + Variational Dropout



- Regularização explícita no tempo, reduzindo overfitting sem quebrar dependências temporais.
- Variational\_dropout utilizado: 0.2


## BiLSTM + Difusão (missingness)



- Regularização implícita via objetivos probabilísticos, forçando robustez a dados ausentes.
- $\mathcal{L} = \lambda_m \mathcal{L}_{miss} + \lambda_v \mathcal{L}_{vae}$


# Variações de treinamento - Regularização

## BiLSTM + LayerNorm



- Estabiliza as ativações internas, com efeito regularizante indireto.

## BiLSTM + AdamW (L2/Weight Decay)



- Usa AdamW em vez de Adam clássico;
- $Weight\ decay = 1 \times 10^{-4}$  para regularizar os pesos e melhorar generalização.

# Configuração Experimental

- Divisão treino/teste: 80% / 20%.
- A quantidade de neurônios já foi validada anteriormente em outra disciplina
- Treinamento por 500 épocas, batch size 256.
- Paciência de 50 épocas para early stopping.
- Função de perda multi-tarefa conforme descrito.
- Otimização e Regularização tratadas como diferentes modelos.
- Otimizador: Adam (exceto variações).
- Taxa de aprendizado inicial:  $3 \times 10^{-4}$ .
- Early stopping baseado no NELBO do teste.
- Avaliação final no conjunto de teste.

- **NELBO** (Negative Evidence Lower Bound):

- Loss probabilística minimizada no treinamento;
- Maximiza implicitamente a verossimilhança (ELBO);
- Balanceia reconstrução e regularização latente (KL).
- $NELBO = \mathbb{E}_{q(z|x)}[-\log p(x | z)] + \text{KL}(q(z | x) \| p(z))$

- **NLL** (Negative Log-Likelihood):

- Generaliza o MSE ao modelar explicitamente a variância da distribuição predita;
- Penaliza erros grandes e variâncias mal calibradas (super ou subestimação de incerteza).
- $$\text{NLL} = -\log p(x | \mu, \sigma^2) = \frac{(x - \mu)^2}{2\sigma^2} + \frac{1}{2} \log \sigma^2 + \text{cte}$$

- **MSE** (Mean Squared Error):

- Erro médio de reconstrução das séries;
- Mede fidelidade gerativa.

- **Cobertura 90%** (`cov_90`):

- Mede a fração de amostras reais que caem dentro do intervalo preditivo teórico [5%, 95%];
- Avalia se o desvio padrão estimado produz uma **calibração probabilística consistente** com a cobertura nominal de 90%.

- **Largura do intervalo 90%** (`width_90`):

- Corresponde à largura teórica do intervalo [5%, 95%] derivado da distribuição predita;
- Quantifica a **sharpness** do modelo: intervalos menores indicam maior confiança, desde que a cobertura permaneça bem calibrada.



# Resultados quantitativos

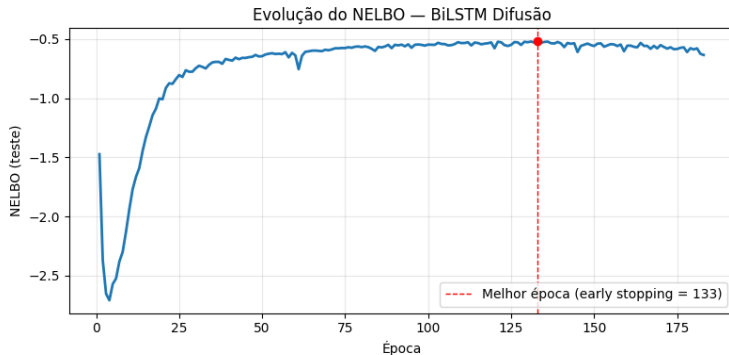
Modelo	NELBO ↓	NLL ↓	MSE ↓	Cov90 → 0.90	Width90 ↓
<b>BiLSTM Difusão</b>	<b>0.518</b>	<b>0.462</b>	<b>0.243 ± 0.067</b>	<b>0.902</b>	<b>2.200</b>
GRU	0.558	0.498	0.300 ± 0.108	0.905	2.252
LSTM	0.588	0.513	0.332 ± 0.129	0.900	2.251
BiGRU	0.589	0.499	0.335 ± 0.136	0.909	2.267
BiLSTM VarDrop 0.2	0.595	0.506	0.317 ± 0.119	0.898	2.240
BiLSTM RAdam	0.597	0.511	0.341 ± 0.139	0.898	2.234
BiLSTM Warmup/Sched.	0.598	0.504	0.354 ± 0.146	0.903	2.251
BiLSTM AdamW	0.601	0.506	0.341 ± 0.141	0.900	2.224
BiLSTM	0.609	0.527	0.337 ± 0.133	0.901	2.269
BiLSTM LayerNorm	0.617	0.514	0.342 ± 0.140	0.907	2.281
DEEP	1.217	1.164	0.693 ± 0.209	0.916	2.785

**Tabela:** Comparação probabilística entre modelos. O critério principal de seleção é a minimização do NELBO. A métrica Cov90 avalia calibração probabilística, cujo valor ideal é próximo de 0.90. A métrica Width90 mede a precisão dos intervalos de previsão e é comparada apenas entre modelos com cobertura adequadamente calibrada.


# Curva de treinamento — Modelo campeão

Evolução do NELBO ao longo das épocas para o modelo **BiLSTM Difusão**.

- Fase inicial instável, com forte variação do NELBO nas primeiras épocas;
- Convergência progressiva para um patamar de NELBO mais estável após dezenas de épocas;
- A melhor época (133) é definida por *early stopping*, privilegiando estabilidade e capacidade de generalização, e não o mínimo pontual da curva.



# Geração de séries — Avaliação qualitativa



## Comparação qualitativa

Séries temporais reais versus séries geradas pelo modelo variacional, comparadas a ajustes ponto-a-ponto baseados em MSE.

A abordagem probabilística captura melhor:

- a distribuição marginal dos sinais;
- a variabilidade temporal;
- a incerteza intrínseca dos dados.

# Discussão dos resultados (modo gerador)

- **Qualidade gerativa:**

- Modelos variacionais recorrentes superam o baseline feedforward;
- **BiLSTM Difusão** apresenta o menor NELBO;
- Redução consistente de NLL e MSE frente a LSTM/GRU unidirecionais.

- **Calibração vs. sharpness:**

- Difusão gera intervalos mais estreitos (menor *width\_90*);
- Cobertura próxima ao alvo de 90%;
- Trade-off equilibrado entre precisão e incerteza.

- **Impacto arquitetural:**

- Bidirecionalidade melhora as representações latentes;
- *GRU fuser* aumenta coerência entre janelas;
- Maior profundidade temporal favorece geração estável.

- **Treinamento e regularização:**

- Difusão atua como principal regularizador probabilístico;
- Dropout e LayerNorm trazem ganhos secundários;
- Otimizadores afetam marginalmente o desempenho.

# Conclusões (modo gerador)

- O framework **TSDf** é eficaz como modelo gerador probabilístico para séries temporais industriais.
- Modelos recorrentes superam o baseline feedforward:
  - Arquiteturas bidirecionais aprendem latentes mais ricos;
  - Fusão temporal melhora coerência de longo prazo.
- **Difusão é decisiva:**
  - **BiLSTM Difusão** é o modelo campeão;
  - Menor NELBO, NLL e MSE, com calibração adequada.
- O modelo permite:
  - Geração de séries realistas e calibradas;
  - Simulação de cenários raros ou críticos.
- Aplicações futuras:
  - Gêmeos digitais industriais;
  - Data augmentation orientada por incerteza.

- Kingma, D. P.; Welling, M. *Auto-Encoding Variational Bayes*. ICLR, 2014.
- Hochreiter, S.; Schmidhuber, J. *Long Short-Term Memory*. Neural Computation, 1997.
- Cho et al. *Learning Phrase Representations using RNN Encoder–Decoder*. EMNLP, 2014.
- Ho, J.; Jain, A.; Abbeel, P. *Denoising Diffusion Probabilistic Models*. NeurIPS, 2020.
- Che et al. *Recurrent Neural Networks for Multivariate Time Series with Missing Values*. Sci Rep, 2018.